

Análise de Vendas do Supermercado —Explicação do Projeto

Visão geral

O projeto analisa todas as vendas de um supermercado em 2023 para responder perguntas de negócio: o que vende mais, quando, para quem e se as promoções funcionam.

É um trabalho de Estatística com três partes:

- **Perguntas de negócio (1 a 10):** respondidas com somas, médias, rankings e gráficos.
- **Estatística descritiva:** resumir cada variável (média, mediana, dispersão, valores atípicos, correlações) e explicar o que cada número quer dizer para a loja.
- **Estatística inferencial (11 a 14):** testes A/B e intervalos de confiança, para saber se uma diferença é real ou só acaso.

Tudo é feito em Python. O arquivo `main.py` responde às perguntas e o arquivo `functions.py` guarda as funções reutilizáveis que o `main.py` chama.

Os dados

O arquivo `csv/vendas_supermercado_com_cliente.csv` tem cerca de 20 mil linhas. Cada linha é uma venda de um produto em um dia de 2023, com dados do cliente que comprou.

Coluna	O que significa	Exemplo
Data	Dia da venda	2023-01-01
Produto	Item vendido	Maçãs
Categoria	Grupo do produto	Alimentos Frescos
Preço	Preço unitário (R\$)	16,46
Quantidade	Unidades compradas	10
Desconto	Desconto aplicado (0 = sem promoção)	0,0
Total_Venda	Valor pago na venda (R\$)	164,60
Idade	Idade do cliente (anos)	49
Renda	Renda do cliente (R\$)	2.715,61

Ao carregar o arquivo, o código cria colunas extras que facilitam as análises:

Coluna criada	Como é calculada
Mes / Nome_Mes	Mês da data (1 a 12 / Jan a Dez)
Dia_Semana	Segunda a Domingo
Faixa_Etaria	Jovem (até 35), Adulto (36 a 59), Idoso (60+)
Tem_Desconto	Verdadeiro quando Desconto > 0

As questões

As perguntas 1 a 10 já têm resposta no main.py. As partes de estatística descritiva e as perguntas 11 a 14 têm as funções prontas em functions.py, mas ainda não são chamadas no main.py.

Perguntas de negócio (1 a 10)

#	Pergunta, em palavras simples	Como o código responde	Resultado principal
1	Quais categorias vendem mais e em que mês cada uma tem seu pico?	Soma o Total_Venda por categoria e por mês; pega o mês de maior valor	Alimentos Frescos lidera com R\$ 1,37 mi (27,7%), 2,6x a Mercearia; pico em março
2	As promoções aumentam as vendas? Quais produtos crescem mais com desconto?	Compara a média com e sem desconto; calcula a variação da quantidade por produto	Venda média cai de R\$ 256 para R\$ 206 com desconto; quantidade quase igual (10,0). Frango (+13,9%) e Farinha (+12,6%) crescem mais
3	Quanto cada categoria vende, em média, por dia?	Soma as vendas de cada dia por categoria e tira a média dos dias	Alimentos Frescos R\$ 3.741/dia; Utilidades Domésticas R\$ 985/dia
4	Quais produtos têm vendas mais sazonais (variam muito ao longo do ano)?	Coeficiente de variação das vendas mensais de cada produto	Descartáveis (23,1%), Vinhos (23,0%), Sucos (22,9%)
5	Qual faixa etária mais contribui para o faturamento?	Soma das vendas por faixa etária e sua participação	Adultos 42,6%, Jovens 31,1%, Idosos 26,3%
6	Como as vendas se distribuem nos dias da semana?	Média, soma e contagem das vendas diárias por dia da semana	Muito equilibrado: de R\$ 13.198 (terça) a R\$ 13.655 (quarta) por dia
7	As vendas de novembro (Black Friday) superam os meses anteriores?	Total por mês e comparação de novembro com outubro e com a média de Jan–Out	Novembro vendeu 7,5% menos que outubro; não houve pico
8	Qual o ticket médio de cada faixa etária, e como muda por categoria?	Média do Total_Venda por faixa etária e por categoria × faixa	Quase igual: Adulto R\$ 247,79, Idoso R\$ 247,33, Jovem R\$ 242,19

9	A idade do cliente influencia o valor da compra?	Correlação de Pearson e de Spearman entre Idade e Total_Venda	$r = 0,01$: nenhuma relação
10	A semana da Black Friday foi melhor que a do Natal?	Vendas diárias de 3 dias antes a 3 dias depois de 24/11 e de 25/12	Natal melhor: R\$ 11.871/dia contra R\$ 10.931/dia

Estatística descritiva

Para Preço, Quantidade, Desconto, Total_Venda, Idade e Renda, o trabalho pede:

- **Centro e dispersão:** média, mediana, moda, desvio padrão, variância, amplitude e coeficiente de variação.
- **Posição:** quartis e percentis.
- **Valores atípicos (outliers):** boxplot, regra de $1,5 \times \text{IQR}$ e z-score, discutindo se devem ser mantidos, tratados ou removidos.
- **Forma:** histograma, assimetria e curtose de Total_Venda e Idade, com comentário sobre normalidade.
- **Tabelas de frequência:** por categoria, faixa etária, dia da semana e mês.
- **Correlação:** matriz de Pearson/Spearman e mapa de calor.

Cada número deve vir com uma frase explicando o que ele significa para a loja.

Estatística inferencial (11 a 14)

Cada teste A/B informa H_0 , H_1 , $\alpha = 0,05$, a estatística do teste, o p-valor e a conclusão para o negócio.

#	Pergunta, em palavras simples	Técnica
11	Vendas com desconto têm valor médio diferente das vendas sem desconto?	Teste A/B (A = sem desconto, B = com desconto)
12	As vendas diárias da semana da BlackFriday diferem das da semana do Natal?	Teste t para duas amostras + IC 95% da média diária de cada semana
13	Qual a faixa provável do ticket médio geral e de cada faixa etária?	IC 95%, discutindo por que alguns intervalos são mais largos
14	A média de vendas de novembro difere da de outubro?	Teste A/B (A = outubro, B = novembro)

O código

O código está dividido em dois arquivos: `functions.py` faz o trabalho pesado e `main.py` usa essas funções para responder cada pergunta, na ordem.

Arquivo	Papel
<code>main.py</code>	Carrega os dados e responde às perguntas 1 a 10, imprimindo tabelas e salvando gráficos
<code>functions.py</code>	Caixa de ferramentas: carregamento, estatísticas, gráficos e testes (importada como <code>f</code>)

Como o `main.py` funciona

1. Importa `pandas`, `numpy`, `matplotlib` e o `functions.py`.
2. Ajusta o `pandas` para mostrar números com 2 casas decimais.
3. Chama `f.carregar_dados(...)`, que lê o CSV e cria as colunas extras.
4. Para cada pergunta: agrupa os dados (`groupby` ou `pivot_table`), calcula somas ou médias, imprime o resultado e, em algumas, salva um gráfico na pasta `graficos/`.

Dois recursos do `pandas` aparecem em quase todas as perguntas:

- **`groupby`**: separa as linhas em grupos (por exemplo, uma pilha por categoria) e resume cada grupo com uma soma ou média.
- **`pivot_table`**: monta uma tabela cruzada, como categorias nas linhas e meses nas colunas.

Funções do `functions.py`

Preparação dos dados

Função	O que faz
<code>carregar_dados</code>	Lê o CSV, converte a data e cria <code>Mes</code> , <code>Nome_Mes</code> , <code>Dia_Semana</code> , <code>Faixa_Etaria</code> e <code>Tem_Desconto</code>
<code>classificar_faixa_etaria</code>	Corta as idades em Jovem, Adulto e Idoso com <code>compd.cut</code>

Aggregações usadas nas perguntas

Função	O que faz
<code>vendas_por</code>	Soma (ou média) do <code>Total_Venda</code> por uma coluna, do maior para o menor
<code>vendas_diarias</code>	Total vendido em cada dia do ano
<code>semana_em_torno</code>	Devolve o início e o fim de uma semana de 7 dias centrada numa data
<code>filtrar_pedidos</code>	Pega só as vendas entre duas datas
<code>coeficiente_variacao_mensal</code>	Mede o quanto as vendas mensais de cada produto oscilam ($\text{desvio} \div \text{média} \times 100$)

Estatística descritiva

Função

medidas_descritivas / tabela_descritiva

interpretar_cv, interpretar_assimetria,
interpretar_curtose

outliers_iqr, outliers_zscore,
resumo_outliers

tabela_frequencia

matriz_correlacao, interpretar_correlacao,
correlacoes_relevantes

O que faz

Calcula média, mediana, moda, desvio, variância, quartis, percentis, assimetria e curtose de uma ou várias colunas

Transformam o número em frase (ex.: "alta dispersão")

Encontram e contam valores atípicos pelas duas regras

Frequência absoluta, relativa e acumulada de uma coluna

Calculam correlações, classificam a força e listam os pares mais fortes

Gráficos (todos salvos em graficos/)

Função

grafico_barras

grafico_linha

grafico_heatmap

grafico_boxplots

grafico_histograma

Gráfico

Barras (ex.: vendas por categoria)

Linha (ex.: vendas por mês)

Mapa de calor (correlações, ticket por categoria × faixa)

Boxplot de cada variável numérica

Histograma com a curva normal para comparação

Estatística inferencial

Função

intervalo_confianca

ic_por_grupo

teste_ab

imprimir_teste_ab, imprimir_ic

O que faz

IC 95% da média usando a distribuição t

O mesmo IC para cada grupo (ex.: cada faixa etária)

Teste t de Welch entre A e B, Mann-Whitney como conferência e d de Cohen (tamanho do efeito)

Imprimem H0, H1, α , estatística, p-valor e a conclusão em texto

Pontos de atenção no código atual

- interpretar_assimetria não trata assimetria negativa (devolve nada) e, para positiva, devolve uma tupla de dois textos em vez de uma frase só; além disso, na assimetria positiva a média fica acima da mediana.
- interpretar_cv escreve "disperção"; o correto é "dispersão".
- As funções de estatística descritiva e inferencial ainda não são chamadas no main.py.

Glossário

Termo	Explicação simples
Média	Soma dos valores dividida pela quantidade
Mediana	Valor do meio quando tudo está em ordem; não é puxada por valores extremos
Moda	Valor que mais se repete
Desvio padrão	Distância típica dos valores até a média
Variância	Desvio padrão ao quadrado
Amplitude	Maior valor menos o menor
Coeficiente de variação (CV)	Desvio padrão em % da média; permite comparar a oscilação de coisas de tamanhos diferentes
Quartis (Q1, Q2, Q3)	Valores que dividem os dados em 4 partes iguais; Q2 é a mediana
Percentil	P90 = valor abaixo do qual estão 90% dos dados
IQR	$Q3 - Q1$: a faixa onde está a metade central dos dados
Outlier	Valor muito fora do padrão (abaixo de $Q1 - 1,5 \times IQR$, acima de $Q3 + 1,5 \times IQR$ ou com z-score acima de 3)
Z-score	Quantos desvios padrão um valor está longe da média
Assimetria	Se a distribuição tem uma "cauda" mais longa para um lado
Curtose	Se as caudas são mais pesadas (mais extremos) ou mais leves que numa curva normal
Correlação de Pearson	Mede relação em linha reta entre duas variáveis (-1 a 1)
Correlação de Spearman	Igual, mas usando a ordem dos valores; menos sensível a outliers
H0 (hipótese nula)	"Não há diferença" entre os grupos
H1 (hipótese alternativa)	"Há diferença" entre os grupos
α (alfa)	Limite de erro aceito, aqui 0,05 (5%)
p-valor	Chance de ver uma diferença desse tamanho só por acaso, se H0 fosse verdade
Termo	Explicação simples
Teste t de Welch	Compara as médias de dois grupos sem supor que têm a mesma variabilidade
Mann-Whitney	Teste parecido que não exige dados com forma normal; usado como conferência
d de Cohen	Tamanho da diferença em desvios padrão; abaixo de 0,2 é pequena
Intervalo de confiança (IC)	Faixa que provavelmente contém a média verdadeira
DataFrame	Tabela do pandas, com linhas e colunas

<code>groupby</code>	Agrupar linhas iguais numa coluna para resumir cada grupo
<code>pivot_table</code>	Cria uma tabela cruzada (linhas × colunas)
<code>pd.cut</code>	Divide números em faixas (ex.: idades em faixas etárias)